

Прогнозирование цен акций с помощью ML/AI (обзор 2023–2025)

Введение. Современные методы машинного обучения (ML) и искусственного интеллекта (AI) широко применяются для прогнозирования цен акций. В период 2023–2025 гг. появилось множество исследований на эту тему. Ниже представлен аналитический обзор ключевых результатов последних лет, включая используемые модели, признаки, методы оценки, ограничения, практические кейсы и перспективы развития.

1. Современные модели

Традиционные vs современные алгоритмы. Классические статистические модели, такие как ARIMA, долгое время служили базовым подходом к прогнозированию временных рядов. ARIMA неплохо моделирует линейные структуры и сезонность и часто используется как бенчмарк. Однако его возможности ограничены при наличии нелинейных зависимостей. Современные исследования показывают, что гибридные подходы могут повысить точность: например, объединение ARIMA с методами ML (XGBoost, нейронные сети) даёт лучший результат, чем любая модель по отдельности ([Survey of feature selection and extraction techniques for stock market prediction - PMC](#)). Это связано с тем, что ML-модели улавливают нелинейные паттерны, дополняя линейные прогнозы ARIMA.

Ensemble и деревья решений. Алгоритмы на основе деревьев решений и бустинга – Random Forest (RF) и eXtreme Gradient Boosting (XGBoost) – широко используются благодаря способности работать с табличными данными и различными типами признаков. Они устойчивы к шуму, требуют минимальной подготовки данных и дают интерпретируемые важности признаков. В сравнительных экспериментах эти методы нередко конкурируют с нейросетями. Так, в одном исследовании по прогнозированию акций Tesla XGBoost показал наименьшую ошибку (MSE/MAPE) и наиболее точно предсказал направление тренда цены по сравнению с LSTM и Random Forest ([F14 CAD023 ICEMESS 2023.docx](#)) ([F14 CAD023 ICEMESS 2023.docx](#)). Random Forest, напротив, хуже остальных улавливал направление (правильно предсказал тренд лишь в ~1.5% случаев) ([F14 CAD023 ICEMESS 2023.docx](#)). Отмечается, что LSTM на тех же данных неожиданно уступил даже Random Forest по точности (выше MAPE), что авторы объясняют наличием длительных “флэтов” в динамике акций, затрудняющих обучение рекуррентной сети ([F14 CAD023 ICEMESS 2023.docx](#)). В

целом же градиентный бустинг (XGBoost) часто демонстрирует высокую точность и низкую ошибку, особенно на краткосрочных интервалах, благодаря эффективному улавливанию нелинейностей.

Глубокие нейросети (LSTM/GRU). Для анализа последовательностей цен популярны рекуррентные нейросети – прежде всего LSTM и GRU. Они учитывают временную зависимость и умеют запоминать долгосрочные паттерны, что важно для финансовых рядов. Исследования в 2023–2024 гг. подтверждают их высокую эффективность: например, модель LSTM достигла $R^2 > 0.99$ при прогнозе цен отдельных акций, тогда как ARIMA дала R^2 около 0.85 ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). Это указывает, что LSTM способна лучше схватывать сложную динамику, чем традиционный подход. В то же время LSTM требуют больших объемов данных для обучения; на коротких исторических выборках они могут переобучаться или попадать в плато. GRU обычно показывает схожие результаты с LSTM, иногда обучаясь быстрее за счёт упрощённой структуры.

Transformers и attention-модели. Новейшее поколение моделей для последовательностей – трансформеры – привлекло внимание финансистов. Архитектура Transformer (включая разновидности типа BERT, GPT) опирается на механизм внимания, хорошо захватывая долгосрочные зависимости. В теории это перспективно для финансовых временных рядов со сложными паттернами. Однако практика пока противоречива. С одной стороны, появились адаптации трансформеров для временных рядов (Temporal Fusion Transformer, Informer и др.), и ряд работ заявляет о конкурентной точности на задачах прогноза рынка. С другой стороны, некоторые исследования отмечают, что стандартные трансформеры могут уступать более простым моделям, если данных недостаточно ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). В экспериментах на касабланкской бирже трансформер показал отрицательные R^2 (то есть хуже случайного угадывания), значительно уступив LSTM и даже ARIMA ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). Авторы связывают это с тем, что для обучения трансформеров требуются очень большие датасеты (как в NLP-задачах), тогда как финансовые данные относительно ограничены ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). Таким

образом, **каждая модель имеет свои плюсы и минусы**: ARIMA проста и интерпретируема, но линейна; RF/XGBoost устойчивы и хорошо работают с признаками, но не учитывают порядок времени явно; LSTM/GRU отлично ловят последовательные зависимости, но требуют много данных; трансформеры теоретически сильны на длинных последовательностях, но на малых выборках могут не раскрыть потенциал. На практике нередко используют ансамбли и гибриды (например, сочетание предсказаний бустинга и LSTM), чтобы компенсировать недостатки отдельных методов.

2. Признаки (features) в моделях

Технические индикаторы и базовые рыночные данные. Большинство моделей используют исторические ценовые ряды и объемы торгов (OHLCV) как базовые признаки. Дополнительно рассчитываются технические индикаторы – скользящие средние, индексы (RSI, MACD, стохастик и др.), волатильность, объёмные показатели. Эти индикаторы суммируют информацию о трендах и настроении рынка, зачастую улучшая качество модели. Однако избыток технических признаков может приводить к переобучению. Обзор методов отбора признаков отмечает, что использование более ~30 технических индикаторов начинает снижать точность классификации из-за «проклятия размерности» ([Survey of feature selection and extraction techniques for stock market prediction - PMC](#)). Поэтому исследователи применяют отбор ключевых индикаторов (например, методы типа Relief, RFE), чтобы оставить наиболее информативные признаки ([Survey of feature selection and extraction techniques for stock market prediction - PMC](#)) ([Survey of feature selection and extraction techniques for stock market prediction - PMC](#)). В совокупности технические факторы помогают моделям уловить краткосрочные паттерны и рыночную динамику.

Фундаментальные и макроэкономические показатели. Чтобы учесть долгосрочную ценность компаний и влияние экономики, в модели вводят фундаментальные признаки (финансовые коэффициенты компаний: P/E, выручка, рентабельность, долговая нагрузка и т.д.) и макроэкономические индикаторы (ставки процента, инфляция, ВВП, цены на нефть/золото, индексы экономики). Эти факторы особенно важны для прогнозирования индексов или отдельных акций на более длинном горизонте. Например, включение в модель данных о будущих изменениях экономической политики (ожидания по ставке и проч.) позволило

заметно повысить точность прогноза акций: RMSE снизился с 1.75 до 1.61 при добавлении этих **anticipated**-макропоказателей ([Boosting Stock Price Prediction with Anticipated Macro Policy Changes](#)). В работе 2024 г. по “AI-аналитику” для акций было показано, что именно макроэкономические переменные дают наибольший вклад в точность модели (около 27.6% условной важности), а второе место занимают сами прошлые доходности акций (24.4%) ([Can AI Predict Future Stock Returns? | Morningstar](#)). Фундаментальные характеристики компаний внесли ~22% вклада, что тоже существенно ([Can AI Predict Future Stock Returns? | Morningstar](#)). Это подтверждает: **макро- и фундаментальные признаки** критически важны для улучшения прогнозов, особенно на горизонте месяцев и лет. Они позволяют ML-моделям учитывать общерыночные тенденции и индивидуальные особенности компаний, которыми нельзя пренебречь.

Новостной фон и сентимент-анализ. В последние годы взрывной рост NLP-технологий привёл к активному использованию текстовых данных (новостей, твитов, постов) для предсказания рынка. Идея в том, что настроения инвесторов и тональность новостей влияют на цены, опережая движение котировок. **Сентимент-анализ** новостей и соцмедиа генерирует признаки, отражающие положительное или отрицательное настроение. Исследования 2023–2024 гг. подтверждают, что добавление таких признаков заметно повышает точность моделей. В частности, при прогнозе цен Apple/Google/Tesla учёт тональности твитов пользователей привёл к значимому снижению ошибок и повышению R^2 модели по сравнению с использованием только ценовой истории ([A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis](#)). Интеграция Twitter-индекса настроений улучшила качество прогноза на **существенную величину**, что подчёркивает силу альтернативных данных ([A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis](#)). Кроме того, в той же работе XGBoost на сочетании цен + твиты превзошёл LSTM, показав лучшую точность, – авторы связывают это с умением бустинга лучше использовать разнородные признаки ([A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis](#)).

Отдельного упоминания заслуживает применение *Large Language Models* для анализа текстов. Lopez-Lira и Tang (2023) продемонстрировали, что оценки новостных заголовков, полученные с помощью ChatGPT, могут предсказывать доходности акций лучше, чем традиционные методы NLP ([My title](#)). **Баллы**

сентимента от ChatGPT значимо коррелируют с последующими дневными доходностями, и особенно сильна предсказательная сила для небольших компаний и при негативных новостях ([My title](#)). Это говорит о том, что современные языковые модели способны “читать” новости почти как аналитики и выделять из них сигналы для рынка.

В целом, наиболее эффективными оказываются **комбинации признаков из разных категорий**. Технические индикаторы помогают ловить краткосрочные паттерны, фундаментальные и макроэкономические данные задают экономический контекст, а новостной сентимент предупреждает о изменениях настроений. Совокупное использование разных типов информации зачастую даёт наибольший прирост точности прогноза ([Can AI Predict Future Stock Returns? | Morningstar](#)). Тем не менее, мультимодальные данные усложняют модель, поэтому важен отбор: как показано в исследовании, текстовые признаки хоть и полезны, но дали лишь ~9% вклада (в сравнении с ~50% суммарно от макро и рыночных факторов) ([Can AI Predict Future Stock Returns? | Morningstar](#)). Таким образом, **правильный выбор признаков** – ключевой фактор успеха ML-моделей на финансовых данных.

3. Оценка качества моделей

Метрики ошибок прогнозирования. Для количественной оценки точности моделей используются стандартные метрики регрессии и классификации. Если цель – спрогнозировать **конкретные цены или доходности**, то популярны метрики ошибки: среднеквадратичная ошибка (RMSE), средняя абсолютная ошибка (MAE), средняя абсолютная процентная ошибка (MAPE) и коэффициент детерминации (R^2). Например, работы сравнивают модели по RMSE/MAE на тестовых данных или сообщают R^2 как меру объяснённой вариации ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). В случае классификации направления движения (рост/падение) применяются метрики Ассурасы (доля правильных предсказаний), Precision/Recall и F1-score для учёта дисбаланса классов. В некоторых исследованиях отдельно рассматривают **Directional Accuracy** – процент случаев, когда модель правильно предсказала знак изменения цены. Так, в эксперименте с Tesla модель XGBoost верно предугадала направление изменения цены более чем в 10% интервалов, тогда как RF – лишь в 1.5% (что фактически на уровне случайности) ([F14 CAD023 ICEMESS 2023.docx](#)).

Финансовые метрики эффективности. Поскольку конечная цель прогнозов цен – заработать на рынке, качества моделей оценивают не только статистическими ошибками, но и с точки зрения прибыли и риска. Распространён подход “перевести” предсказания в торговую стратегию и измерить её показатели: совокупную доходность, волатильность, коэффициент Шарпа (отношение средней прибыли к риску). Например, если модель предсказывает рост – покупать, падение – продавать (шортить); затем анализируют прибыльность такой стратегии. Хорошая модель должна давать **положительный риск-скорректированный доход**. В ряде работ по глубокому обучению для трейдинга вычисляли коэффициент Шарпа модельных стратегий и сравнивали с бенчмарком (рынком или стратегией “buy and hold”). Одно из исследований с использованием LLM для генерации торговых решений показало, что сформированный портфель обладает высоким Sharpe Ratio, превосходя бенчмарк, что подтверждает практическую ценность модели ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)). Однако финансовые метрики нужно применять осторожно: высокое R^2 или Accuracy не гарантирует высокую прибыль из-за транзакционных издержек и ограничений по выполнению сделок.

Методы валидации моделей. Корректная оценка требует разделения данных на обучающие и тестовые, особенно во избежание *look-ahead bias* (подглядывания в будущее). Стандартом стало **разделение по времени**: например, обучить модель на данных 2010–2020 гг., а проверять на 2021–2022 гг. (или брать последние 10–20% выборки под тест) ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). Многие работы именно так и поступают, имитируя реальный сценарий, когда будущее неизвестно. Также применяется **скользящая (rolling) или расширяющаяся (expanding) проверка**: модель многократно переобучается на окнах (например, train: 2010–2018, test: 2019; потом train: 2010–2019, test: 2020 и т.д.), и метрики усредняются (). Такой *rolling cross-validation* учитывает возможную нестабильность рынка во времени и проверяет, как модель адаптируется к новым данным. Важное отличие от классической k-fold кросс-валидации – недопущение утечки информации: валидационные окна всегда находятся **хронологически впереди** обучающих (). В некоторых случаях вводят “embargo” – пропуск небольшой паузы между train и test, чтобы исключить автокорреляции ().

Строгая out-of-sample проверка – залог надёжности выводов. Лучшие исследования публикуют результаты на **нескольких метриках** (например, и MAPE, и Ассигасу, и Sharpe) и на **нескольких периодах или активах**, показывая устойчивость модели. Также практикуется сравнение с простыми базовыми правилами (напр., всегда предсказывать “рост” или “падение” по тренду) и проверка статистической значимости превосходства модели над случайным угадыванием. Если модель применяется для стратегии, часто моделируют и худшие сценарии, стресс-тесты, чтобы учесть риски.

4. Ограничения и противоречия

Несмотря на прогресс, **прогнозирование фондового рынка остаётся крайне сложной задачей**. Есть ряд фундаментальных ограничений, которые выявляются и в современных исследованиях:

- **Шум и непредсказуемость данных.** Цены акций формируются под воздействием бесчисленных факторов – экономических, политических, поведенческих. Большая часть вариации представляет собой шум, а сигналы весьма слабы. Теория случайного блуждания и гипотеза эффективного рынка (Фама) утверждают, что будущие изменения цен *непредсказуемы* на основе одной лишь прошлой информации ([Survey of feature selection and extraction techniques for stock market prediction - PMC](#)). Многие эксперты поддерживают это: если рынок эффективен, то любые паттерны сразу же арбитражируются участниками, оставляя только случайные колебания. В таком мире даже самые сложные ML-модели будут неспособны существенно обыграть простые стратегии.

- **Ограниченность и смещение данных.** Исторические данные по акциям имеют ограниченный объём (особенно для отдельных компаний или с учётом редких событий). ML-модели рискуют *переобучиться* на историю, которая не повторится. Например, глубокая сеть может идеально подогнаться под кризис 2008 г. и упустить, что в будущем шоки будут иного характера. Кроме того, данные страдают от смещений: успешные компании выживают (survivorship bias), меняются режимы монетарной политики, происходят структурные сдвиги. Модель, обученная на одном режиме, может дать сбой при смене условий.

- **Неучёт неожиданных событий.** Самые сильные движения рынка часто вызываются **шоками** – финансовыми кризисами, пандемиями (пример – COVID-19 в 2020 г.), войнами, регуляторными сюрпризами. Эти события *не заложены в данные*, пока не случатся, поэтому прогнозировать их практически невозможно. AI-модели, обученные на спокойных периодах, не предсказывают внезапный обвал или всплеск волатильности. Например, многие алгоритмы, успешно работавшие до весны 2020, не смогли заранее сигнализировать обвал, поскольку не имели аналогов пандемии в обучении. Рыночные аномалии (типа эпизода GameStop 2021) вызваны уникальными сочетаниями факторов, которые также трудно учесть. Таким образом, **черные лебеди** остаются ахиллесовой пятой прогнозирования с помощью ML/AI.

- **Противоречивые результаты исследований.** В литературе прослеживаются разнородные выводы о эффективности AI на рынке. Наряду с оптимистичными работами, есть и скептические. Например, масштабный анализ ML-моделей для предсказания доходностей показал, что на больших ликвидных акциях сложные модели *не дают существенного преимущества*: для компаний с большой капитализацией избыточная доходность стратегий на основе ML за последние 20 лет оказалась около нуля либо отрицательной ([MLMs: do they work better than traditional approaches?](#)). Иными словами, на крупных рынках машины не лучше традиционных факторных стратегий, особенно после учета рисков. Улучшения от ML наблюдаются лишь на малых фирмах или коротких горизонтах (где есть небольшая неэффективность), но исчезают на масштабах S&P 500 ([MLMs: do they work better than traditional approaches?](#)) ([MLMs: do they work better than traditional approaches?](#)). Кроме того, даже когда модель на исторических данных показывает высокий Sharpe Ratio, в реальности достичь его сложно. Оценки указывают, что **достижимая** прибыльность существенно ниже идеальной: реальные коэффициенты Шарпа могут быть на порядок меньше модельных, из-за ограничений по ликвидности, задержек исполнения, конкуренции других алгоритмов (Da et al. (2022) отмечают, что каким бы алгоритмом ни пользовались арбитражёры, им вряд ли удастся реализовать “оптимальные” прибыли, предсказанные

моделью (). Эти результаты возвращают к мысли об эффективности рынка и том, что бесплатных обедов не бывает.

- **Оверфиттинг и стабильность.** Модель, превосходно работающая на тесте сегодня, может *деградировать* со временем. Финансовые данные не стационарны: параметров, настроенных под прошлое, может хватить ненадолго. Исследования указывают на проблему перенастройки моделей (например, ежемесячной) и снижения их точности вне изначального периода ([MLMs: do they work better than traditional approaches?](#)). Появляется эффект *перегонки задвигающейся цели* (“moving target”): как только стратегия становится известна и распространена, её эффективность падает. Именно поэтому практики часто переобучают модели регулярно и используют ансамбли, добавляют случайность, чтобы избежать предсказуемости.

В совокупности, **низкая предсказуемость рынка** и риски переобучения – главные препятствия. Существуют работы, прямо указывающие на слабую пользу сложных моделей: мол, простые подходы не сильно уступают, учитывая все издержки. Тем не менее, другие исследования демонстрируют улучшения за счет AI, особенно в сочетании с экспертным подходом. Таким образом, в академическом сообществе нет полного консенсуса – эффективность ML/AI в трейдинге зависит от условий и корректности методологии. Признано, что даже лучшие алгоритмы не способны с уверенностью предсказывать все движения рынка, но могут дать *статистическое преимущество* (пусть и небольшое), которым умелые трейдеры воспользуются.

5. Практические применения

Корпорации и хедж-фонды. В индустрии финансистов AI уже стал неотъемлемым инструментом. Крупные инвестиционные банки, хедж-фонды и проп-трейдинговые фирмы вкладывают ресурсы в разработку ML-моделей. Многие детали засекречены, но известно, что фирмы вроде **Two Sigma, Citadel, BlackRock** используют ML для выявления скрытых паттернов в данных и оптимизации портфелей. Появляются даже полностью AI-управляемые фонды. Например, ETF под тикером AIEQ (AI Powered Equity ETF) был запущен с стратегией, генерируемой моделью IBM Watson. Хотя его результаты не однозначны, сам факт иллюстрирует попытку доверить выбор акций ML-алгоритму.

Стартапы и финтех. Стартап-среда также активно внедряет AI в трейдинг. Проект **Numerai** представляет интересный кейс: это хедж-фонд, который проводит соревнования среди дата-сайентистов, предоставляя им обезличенные финансовые данные. Множество моделей объединяются в мета-модель фонда, который управляет капиталом – по сути *crowd-sourced* подход к AI-трейдингу. Другие стартапы разрабатывают системы анализа настроений: например, **StockTwits** и **EquityGPT** анализируют соцсети и новости, сигнализируя трейдерам. **Kensho** (поглощён S&P Global) специализировался на AI-анализе рыночных событий. Кроме того, финтех-компании предлагают розничным инвесторам ML-инструменты: боты, советники (robo-advisors) с элементами AI, прогнозные сервисы в торговых приложениях.

Исследовательские подразделения Big Tech. Большие технологические компании также внесли вклад. Яркий пример – **BloombergGPT**, собственная большая языковая модель от Bloomberg (2023 г.). Это 50-миллиардная модель, обученная на 363 млрд токенов финансовых данных – от новостей и документов до рыночных временных рядов ([\[PDF\] BloombergGPT: A Large Language Model for Finance](#)). BloombergGPT способна решать широкий спектр задач: ответ на вопросы по финансам, классификация новостей, заполнение пропущенных данных и даже элементарный прогноз временных рядов. По заявлению разработчиков, она значительно превосходит предыдущие открытые модели аналогичного размера на финансовых задачах ([Vadim Dabravolski - Google Scholar](#)). Хотя BloombergGPT – прежде всего NLP-модель, её создание свидетельствует об интересе крупного бизнеса к специализированным AI-системам для рынков. Также **Google Research** и **Microsoft Research** публиковали работы по финансовому AI: от улучшения временных рядов (например, алгоритмы AutoML для прогнозирования) до применения трансформеров к экономическим данным. Эти корпорации зачастую открывают библиотечные решения – к примеру, Google в 2023 г. в составе TensorFlow представила обновления для Time Series API, учитывающие наработки исследований.

Инновационные подходы. На стыке 2024–2025 гг. появилось несколько новых направлений в применении AI к финансам. Во-первых, **мультимодальные модели**, способные одновременно обрабатывать числовую и текстовую информацию. В классическом подходе приходилось отдельно извлекать признаки из новостей (например, индекс настроений) и подавать их вместе с ценами в

модель. Теперь же разрабатываются архитектуры, где нейросеть сама читает новости и смотрит график цены одновременно. Пример – подход *Summarize-Explain-Predict (SEP)*, предложенный Коа и соавт. (2024): большая языковая модель сначала суммирует поток новостей/твитов, затем генерирует объяснение вероятного движения акции, и на этой основе выдаёт прогноз ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)) ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)). По сути, LLM выступает как виртуальный аналитик, который читает тексты и делает вывод о влиянии на цену, еще и поясняя свой ход мыслей. Эта система с самообучением через self-reflection и RL (PPO) достигла более высокой точности прогноза направления, чем традиционные LSTM, и продемонстрировала лучший показатель MCC (Matthews Correlation) на классификации “рост/падение” ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)). Также при тестировании на портфельных стратегиях такой **LLM-подход** показал высокий Sharpe Ratio, то есть не только предсказывал движение, но и позволял собрать прибыльный портфель ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)).

Во-вторых, развивается **глубокое обучение с подкреплением (DRL)** в задачах торговли. Вместо явного прогнозирования цен, агент с RL учится напрямую совершать сделки и максимизировать доход. Например, DQN- и PPO-агенты тренируются на исторических данных: когда покупать, продавать или держать. Доклады сообщают, что DRL-стратегии способны обыгрывать базовые правила, хотя и чувствительны к параметрам и рыночным фазам ([Analyzing Deep Reinforcement Learning Strategies for Enhanced ...](#)) ([Deep Reinforcement Learning Strategies in Finance - arXiv](#)). Некоторое время назад DeepMind применила RL для оптимизации исполнения крупных ордеров (т.н. *trade execution*), а сейчас концепция расширяется на задачи портфельного управления. DRL интересен тем, что он внутренне сочетает прогнозирование с принятием решений, и может учитывать транзакционные издержки и риск в процессе обучения.

Практические результаты и кейсы. Реальные отзывы о применении ML/AI в трейдинге разнообразны. Одни фирмы сообщают о повышении эффективности торговли, снижении рисков благодаря моделям предсказания риска и детекции аномалий (например, алгоритмы мониторинга мошенничества на рынке). Другие

признают, что полностью полагаться на “черный ящик” пока рано – требуется контроль со стороны человека. Примечателен вывод недавнего академического исследования: **сочетание человека и машины** зачастую дает лучший результат, чем каждый по отдельности ([Stock analysis: How does AI perform vs. humans?](#)). В работе Cao et al. (2024) из JFE сравнили: индивидуально AI-аналитик победил ~54.5% профессиональных аналитиков в прогнозе годовых доходностей акций, а топ-аналитики победили AI в ~45.5% случаев ([Stock analysis: How does AI perform vs. humans?](#)). Однако “человек + AI” в тандеме обошли чисто AI-модель уже в 54.8% случаев, существенно сократив число крупных ошибок ([Stock analysis: How does AI perform vs. humans?](#)). Этот кейс указывает, что **синергия** экспертного знания и вычислительной мощности может быть оптимальным путём: алгоритмы быстро переваривают большие данные, а человек привносит интуицию и контекст.

Таким образом, на практике AI в финансах используется повсеместно – от вспомогательного анализа данных (скрининг новостей, генерация торговых идей) до автономных стратегий. Инновации вроде специализированных языковых моделей (BloombergGPT, FinGPT), мультимодальных нейросетей и RL-агентов расширяют арсенал. В то же время индустрия осознаёт риски: модели тщательно тестируются, внедряются поступательно. Регуляторы тоже следят за ситуацией, обсуждая правила для AI-алгоритмов торговли (во избежание флеш-крэшей и пр.). Но общий тренд очевиден: **AI становится частью “оружия” трейдера**, повышая скорость и обоснованность решений.

6. Заключение

На 2025 год применение ML/AI для прогнозирования рынка – это уже не экзотика, а обыденная практика и активно исследуемая область. Современные модели способны извлекать слабые сигналы из огромных массивов данных, иногда выдавая статистически значимые и полезные предсказания ([My title](#)). Накоплен положительный опыт: нейросети (особенно LSTM) и ансамбли бустинга обгоняют классические подходы в ряде задач краткосрочного прогноза, а обработка новостей языковыми моделями даёт дополнительную информацию, недоступную из одних чисел. Тем не менее, **ожидать чудес не стоит**. Фондовый рынок по-прежнему во многом непредсказуем и близок к эффективному. ML-модели сталкиваются с шумом, неполнотой данных и сменой режимов – то есть с теми же проблемами, что и классические модели, хоть и на новом витке.

Насколько разумно применять ML/AI для предсказания рынка сегодня? Вероятно, наиболее разумно – как вспомогательный инструмент. AI уже доказал свою полезность в ускорении анализа и обнаружении аномалий, генерации торговых сигналов, но **автоматически “обыграть рынок”** с помощью одной только модели всё ещё крайне сложно. Лучшие результаты достигаются, когда AI интегрирован в общий процесс принятия решений человека. Системы “человек + машина” позволяют снижать ошибки и совмещать лучшее из обоих миров ([Stock analysis: How does AI perform vs. humans?](#)). Перспективы развития в ближайшие годы включают дальнейшее усложнение моделей (большие мультимодальные архитектуры, объединяющие текст, числа, изображения), внедрение *online-learning* подходов для непрерывной адаптации к новым данным, а также широкое распространение специализированных финансовых LLM. Интересно, что сами исследователи предсказывают: по мере массового внедрения LLM и других AI на рынке **эффективность рынка возрастёт**, и возможность получать сверхдоходы сократится ([My title](#)). Иронично, но более умные модели могут сделать рынок более непредсказуемым (в смысле уменьшения арбитражных возможностей), “развеяв” оставшиеся неэффективности.

В заключение, ML/AI уже приносит пользу в трейдинге – при грамотном применении он улучшает информированность и скорость реакций на события. Однако основные ограничения – рыночный шум, “чёрные лебеди”, риск переобучения – никуда не делись. Перспектива в том, чтобы совершенствовать модели и методы, **но** воспринимать их как помощников, а не “волшебный шар”. В 2025 году разумно использовать AI для поддержки принятия решений на рынке, осознавая, что окончательное слово остаётся за человеческой оценкой и управлением рисками.

7. Ключевые источники

- **Lopez-Lira, A., Tang, Y. (2024). “Can ChatGPT Forecast Stock Price Movements?”** (arXiv:2304.07619). – Исследование возможностей больших языковых моделей (ChatGPT) в прогнозировании доходностей акций на основе новостных заголовков. Показано, что *LLM*-сгенерированные сентимент-оценки значительно предсказывают последующие дневные доходности, превосходя традиционные методы анализировать тексты ([My title](#)). Выявлено, что эффект сильнее на мелких акциях и при негативных

новостях, а широкое внедрение таких моделей может повысить эффективность рынка ([My title](#)) ([My title](#)).

- **Lahboub, K., Benali, M. (2024). “Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices”** (*Journal of Risk and Financial Management*, 17(7), 293. DOI: 10.3390/jrfm17070293). – Сравнительное исследование трёх моделей (ARIMA, LSTM, трансформер) на прогнозировании цен компаний марокканской биржи. LSTM показал лучшую точность прогнозов (R^2 до 0.99), заметно превзойдя ARIMA ($R^2 \approx 0.85$), тогда как трансформер уступил, дав отрицательный R^2 ([Assessing the Predictive Power of Transformers, ARIMA, and LSTM in Forecasting Stock Prices of Moroccan Credit Companies](#)). Работа подчёркивает эффективность LSTM для финансовых временных рядов и указывает, что трансформеры требуют более обширных данных для конкурентной работы.

- **Cao, S., Jiang, W., Wang, J., Yang, B. (2024). “From Man vs. Machine to Man + Machine: The Art and AI of Stock Analyses”** (*Journal of Financial Economics*, in press; SSRN ID: 4112168). – Статья исследует, как AI-модель (“AI-аналитик”) справляется с прогнозом доходностей акций относительно человеческих аналитиков, и что даст их комбинация. Выводы: AI превзошёл 54.5% индивидуальных прогнозов аналитиков ([Stock analysis: How does AI perform vs. humans?](#)), однако люди лучше в нишевых случаях (малые фирмы, высокая неопределённость) ([Stock analysis: How does AI perform vs. humans?](#)). Синергия человека и машины оказалась наиболее эффективной: гибридная модель “Man + Machine” уменьшила долю крупных ошибок и обошла сам AI ещё в ~54.8% случаев ([Stock analysis: How does AI perform vs. humans?](#)). Это демонстрирует потенциал сотрудничества AI с экспертами в финансах.

- **Koa, K. J. L. et al. (2024). “Learning to Generate Explainable Stock Predictions using Self-Reflective LLMs”** (The Web Conference 2024, OpenReview preprint). – Предложена новая мультимодальная архитектура на базе большой языковой модели для прогнозирования акций с одновременной генерацией текстового объяснения. Модель анализирует веб-контент (новости, соцмедиа) и выдает прогноз направления цены с обоснованием. Для обучения используется саморефлексия и метод PPO. Результат: модель

превзошла классические глубокие модели по точности прогноза и метрике MCC, а тестирование в задачах формирования портфеля показало высокий Sharpe Ratio стратегии ([Learning to Generate Explainable Stock Predictions using Self-Reflective Large Language Models | OpenReview](#)). Этот источник иллюстрирует передовой подход к объединению NLP и финансового прогнозирования.

- **Haque, M. S. et al. (2023). “Boosting Stock Price Prediction with Anticipated Macro Policy Changes”** (arXiv:2311.06278). – Работа посвящена улучшению точности прогноза акций за счет учёта *ожидаемых* изменений макроэкономической политики. Авторы добавляют в модель информацию о будущих решениях (напр., ожидаемые изменения ставки) помимо текущих макропоказателей. Выяснилось, что включение таких данных существенно снижает ошибку прогноза (RMSE 1.61 vs 1.75 у базовой модели) ([Boosting Stock Price Prediction with Anticipated Macro Policy Changes](#)) и улучшает результаты на различных ML-алгоритмах. Это указывает на важность упреждающих макро-факторов и реакции инвесторов на ожидания.

- **Wu, S. et al. (2023). “BloombergGPT: A Large Language Model for Finance.”** (arXiv:2303.17564). – Описание первой специализированной LLM для финансов от Bloomberg. Модель 50 млрд параметров, обучена на 700+ млрд токенов, сочетая общие и финансовые тексты. BloombergGPT показывает превосходство над существующими open-source моделями такого же масштаба в ряде финансовых задач (анализ новостей, ответ на вопросы, заполнение данных и т.п.) ([Vadim Dabravolski - Google Scholar](#)). Хотя непосредственно прогноз цен не в фокусе, модель включает задачи по временным рядам и может применяться для оценки рынка. Данный источник демонстрирует стремление индустрии создавать большие модели, понимающие финансовый язык и данные.

- **Kelly, B., Xiu, D. (2023). “Financial Machine Learning.”** (University of Chicago BFI Working Paper No. 2023-100). – Обширный обзор (survey) по применению ML в финансах. Охватывает темы от предсказания доходностей акций до управления портфелями с помощью ML. Авторы обсуждают проблемы переобучения, методики кросс-валидации на временных рядах, *information leakage*, и влияние сложности моделей на реальные результаты.

Отмечается, что усложнение моделей повышает потенциальный Sharpe Ratio, но реальный выигрыш нивелируется дисперсией и ограничениями на арбитраж (). Рекомендуется использовать специальные техники валидации для временных данных (rolling, блокированная CV с “embargo”) () (). Этот источник ценен как консолидированное знание о состоянии финансового ML.

- **Ouf, S. et al. (2024). “A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis.”** (*Int. J. of Advanced Computer Science and Applications*, 15(12), 207-215). – Статья рассматривает влияние добавления данных Twitter-сентимента на точность прогнозирования цен акций. Реализован гибридный LSTM + XGBoost, который получает на вход как исторические цены, так и рассчитанные NLP-метрики настроения твитов. Эксперименты на акциях Apple, Google, Tesla показали, что **учёт тональности** сообщений пользователей соцсетей существенно повысил точность (снизил RMSE, повысил R^2) по сравнению с моделью, обученной только на ценах ([A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis](#)). Также обнаружено, что XGBoost слегка опередил LSTM в этой задаче ([A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis](#)). Данная работа иллюстрирует практическую ценность социального сентимента как источника данных для моделей.